МГТУ им. Н.Э. Баумана, кафедра ИУ6, дисциплина «Продуктовая аналитика»

Требования к датасету семестрового проекта

1 Зачем выбирать датасет

От датасета зависит, насколько ваш проект будет иметь смысл. Если на данных нельзя честно посчитать **LTV/CAC и когортный retention** или построить прогноз лучше наивного baseline — датасет не принимается, сколько бы в нём ни было строк, потому что в нём нет смысла.

При этом **структуру данных не задаём.** Таблиц `users` / `events` / `payments` может не быть: важно не то, как разложены данные, а то, что из них собираются все нужные расчёты.

2 Требования к датасету

Что должно быть в данных	Размер
Пользователь с датой появления и идентификатором	5 000 / 20 000+
Действия пользователя со временем (тип, метка времени)	100 000 / 500 000+
Платежи или выручка: сумма и дата	1 000 / 5 000+
Расходы на привлечение и маржа/себестоимость	по каналам
Ряд по дням (DAU или выручка) с трендом/сезонностью	90 / 120–365 дней
Возможность определить отток: правило «нет события N дней»	100+ / ≥ 1 000 отточных пользователей
Количество срезов (канал, устройство, гео)	2 / 3+ измерения
Реалистичные дефекты (пропуски, дубли, выбросы, тестовые записи)	порядка 5 % строк

Размеры даны как **минимум / оптимум**. **Пункт можно не выполнять, если датасет честно применим для остальных модулей** — например, нет платежей, но продукт не монетизируется в данных; ограничение фиксируется в отчёте.

3 Что точно не подходит

- в датасете нет различимого пользователя; невозможны когорты, LTV, сегментация;
- окно < 30 дней или пользователей < 500; не получится посчитать когорты и метрики;
- нет оттока, платежей или временны́х меток;
- явно «игрушечные» синтетические данные: равномерные ID, отсутствие выбросов, идеальная воронка;
- данные не являются продуктовыми по сути.

Синтетика допускается, если она реалистичная: распределения, корреляции и дефекты похожи на настоящие, включая скошенные метрики, зависимость удержания от канала, правдоподобный шум.